

ShipVoice 船厂安全实时语音问答助手项目报告

课程：信息安全基础

选题：A2级联式造船语音问答系统的复现与改进

项目名称：ShipVoice船厂安全实时语音问答助手

小组成员：李星烁 许奕 肖相宇 张洛梧 林琪 金子涵 夏弘泰

摘要

ShipVoice 是面向船厂高风险作业场景的实时安全语音问答系统。本项目依据课程A2要求，复现并扩展由自动语音识别（ASR）、语言模型（LLM）与语音合成（TTS）构成的级联式语音问答链路，在基础原型之上集成领域知识检索、证据引用、安全门控、运行审计与管理后台等模块，形成可运行、可测量、可复盘的完整应用。用户可通过文本输入、音频上传或浏览器录音提交问题；系统依次完成语音转写、船厂术语后处理、安全门控、检索增强生成（RAG）、语言模型推理与语音合成，输出附证据依据的安全建议，并支持语音播报。

本项目的改进体现在三个层面：其一，在级联链路中引入船厂安全领域约束，对越界、危险及提示注入类输入实施多层次拦截，避免生成不合规内容；其二，建立 RAG 证据检索与引用展示机制，使回答与知识条目 ID、来源、风险等级、置信度及匹配词绑定，降低大模型幻觉风险；其三，构建可复现评测体系，对安全门控、ASR 术语识别、多轮问答、引用质量及真实语音链路进行量化评估，并在远程 GPU 环境完成 300 次仅依赖真实服务的重复实验。

实验结果表明，系统在安全门控、术语识别、多轮问答、引用质量及真实语音链路等方面均取得可复现的量化结果。安全门控评测集含 56 条样本，决策准确率 100%，误放行（false allow）为 0；50 条真实录音经术语后处理，平均字错误率/词错误率（CER/WER）为 0，术语召回率 100%；多轮问答评测含 6 组对话共 18 轮，追问语境保持准确率（follow-up grounding accuracy）为 100%；引用质量评测中 title hit@3、ID hit@3 及答案引用 ID 覆盖率均为 100%。真实链路实验中，在门控放行（gate-allowed）配对样本上，流式改进相对串行基线平均缩短首段可播放延迟 4147.39ms；浏览器端 audio.onplaying 观测 20 条样本全部播放成功，平均首播延迟 4093.5ms。系统采用 real-only 运行策略：ASR、LLM、TTS 均接入真实服务提供商，任一环节不可用时请求失败并记录日志，不以静态示例替代真实运行结果。

1. 选题背景与需求分析

1.1 应用场景

船舶制造涵盖密闭舱室作业、动火作业、吊装作业、管路试压、高处作业、喷涂作业、临时用电等多种高风险场景。一线人员在作业现场遇到安全问题时，往往需要快速获取规范化处置建议；传统安全手册、制度文件与培训材料存在检索效率低、表述与现场语境脱节、难以支撑多轮追问等局限。语音问答系统可在该场景中发挥辅助作用：作业人员以口头方式提问，系统完成语音转写并返回结构化安全建议。

课程A2的核心要求是构建级联式语音问答系统，即ASR负责语音转写，语言模型负责理解与生成，TTS 负责语音播报；同时需围绕首段可播放延迟与主观等待体验开展可量化对比，并提交系统架构、模块版本与配置、基线与改进指标对比表、可复现实验步骤，以及改进点与局限说明。ShipVoice 在上述要求基础上进一步落实信息安全属性：系统不仅需回答操作层面的问题，更需判断问题本身是否应当被回答，并对危险请求与提示注入实施拦截。

1.2 项目定位

从工程与安全双重目标出发，船厂安全问答系统不宜设计为无边界通用聊天机器人。系统须对符合安全规范的问题给出有据可依的建议，对绕过审批、破坏报警装置、规避监护等越权或危险请求予以拒答，并对舾装阶段、压载水舱、测氧测爆、有限空间、动火作业等造船专有术语保持识别鲁棒性——ASR 误听将沿级联链路传递，可能导致检索偏移与回答失准。据此，本项目将低延迟优化、领域知识增强与安全控制列为同等优先级的设计目标。

ShipVoice定位为可运行、可测量、可复盘的船厂安全语音问答系统原型，而非静态展示页面。系统满足 A2 对级联链路、延迟对比与实验复现的要求，并体现信息安全课程对输入安全、生成安全、证据安全与运维安全的关切。

1.3 典型用例

用户角色	典型场景	系统期望行为
舱室作业人员	询问有限空间作业前的安全检查事项	ASR 转写 → 术语纠错 → 门控放行 → RAG 检索 → 返回带引用的安全建议并 TTS 播报
动火监护人员	追问气体异常出现后的后续处置步骤	结合多轮上下文（history），保持与前文一致的语境绑定
恶意或误操作输入	要求忽略安全规则并给出违规动火方法	安全门控短路拒答，不调用 LLM，不合成违规操作音频
系统维护人员	更新知识库、查阅运行记录、检查服务健康状态	通过管理后台完成知识治理、审计复盘与评测任务

2. 项目目标

本项目依据课程A2要求与船厂安全应用需求，确立以下五项建设目标。


- (1) 系统须具备真实可运行能力。前端支持文本提问、音频上传、浏览器录音、结果展示与TTS播放；后端提供标准API、WebSocket事件流、健康检查、运行审计与管理后台。
- (2) 系统须体现造船安全领域特征。知识库、评测集、术语表、拒答规则与示例问题均围绕船厂安全作业构建，不采用泛化开放域问答数据集。
- (3) 系统须具备明确的安全边界。对off-domain、unsafe、prompt injection、boundary等输入类别，须给出明确的放行或拒答决策，避免因大模型生成能力过强而输出不当内容。
- (4) 系统须建立量化实验体系。延迟优化须记录 ASR、检索、LLM、TTS、首段音频及总耗时等阶段指标；安全增强须通过测试集统计准确率、false allow、false block等客观指标，而非定性描述。

(5) 系统须支持实验复现。须提供明确的启动、测试、后台操作与实验复现步骤，并说明ASR、LLM、TTS端点配置及健康检查方法。

3. 总体系统设计

3.1 应用架构概览


ShipVoice采用前后端一体的FastAPI应用架构。用户端提供现场问题输入、音频上传、浏览器录音与结果展示；后端执行问答主链路；管理后台承担知识库治理、运行记录管理、评测任务调度与provider健康检查。系统通过统一的真实provider抽象层接入ASR、LLM、TTS，可对接FunASR/SenseVoice、OpenAI-compatible Qwen/vLLM服务及HTTP TTS 服务。整体处理链路如下：



安全门控位于RAG与LLM之前：当输入属于危险请求、无关话题或提示注入时，系统不调用语言模型生成详细操作步骤，而短路返回安全提示或拒答答复。RAG检索位于语言模型之前，使回答依托本地知识库而非完全依赖模型参数记忆。TTS置于链路末端，在输出语音结果的同时保留文本结果，供运行记录与事后复盘使用。

3.2 系统架构图

下图展示ShipVoice自用户输入至审计落库的完整数据流，含baseline与streaming两种响应模式分支。



架构设计要点如下：

1. Fail-closed策略：ASR、LLM、TTS任一真实服务不可用时，请求直接失败并写入审计日志，不返回虚假答案或虚假音频。
2. 门控前置：危险输入在LLM调用之前被拦截，避免先生成后过滤带来的合规风险。
3. 双模式延迟对比：同一pipeline支持baseline（串行等待完整回答）与streaming（句级TTS首段优先），满足A2基线与改进方案的对比要求。
4. 双端延迟测量：服务端记录first_audio_ready_ms，浏览器端记录audio.onplaying，避免单一指标掩盖用户侧真实等待体验。

3.3 代码分层

层级	主要文件	作用
配置层	configs/pipeline.json, configs/runtime.*.env	定义 provider、延迟目标、术语表、拦截关键词、运行模式
数据模型层	src/shipvoice/models.py	定义问答事件、门控结果、检索结果、指标结构
Provider层	src/shipvoice/providers.py	封装真实 ASR、RAG、LLM、TTS provider；服务缺失时 fail-closed

层级	主要文件	作用
Pipeline 层	src/shipvoice/pipeline.py	串接 ASR、后处理、门控、检索、生成和合成，输出运行事件与指标
API 层	src/shipvoice/fastapi_app.py	提供用户端 API、WebSocket、后台 API、健康检查和评测任务接口
持久化层	src/shipvoice/sqlite_store.py	保存知识库、运行审计、评测数据、case ledger 和配置快照
前端层	web/static/index.html, web/static/app.js, web/static/styles.css	用户工作台，支持文本、上传、录音、结果展示和运行详情
后台层	web/static/admin.html, web/static/admin.js	管理后台，支持知识库治理、评测、provider health 和运行复盘
远端服务	remote/serve_funasr_asr.py, remote/serve_transformers_openai.py, remote/serve_edge_tts.py	GPU 侧 ASR、LoRA LLM、TTS 独立进程
实验脚本	scripts/*.py	运行安全门控、ASR、多轮、citation、真实链路和等待体验评测

4. 系统运行截图

本章截图均取自本地实际运行实例（FastAPI应用 + 管理后台 + Swagger文档）。截图反映系统界面布局、知识治理能力与API结构；Provider Health面板同时如实显示本地演示环境下ASR、LLM、TTS 远端服务未启动时的 unreachable 状态，体现 real-only 策略下 fail-close 的可观测性。

4.1 用户端工作台

用户端采用深色工业安全控制台风格。左侧为现场问题输入区，支持文本提问、音频上传与浏览器录音；下方提供快速场景与高级选项折叠入口。右侧主工作区按优先级展示安全建议、安全结论、引用依据与当前问题；链路耗时、阶段状态与运行日志收纳于运行详情面板，默认折叠。




图 4-1 用户端工作台

界面说明：

区域	功能
左侧 ON DUTY 面板	说明系统用途：输入作业问题，返回安全结论、处置建议与引用依据
现场问题	文本输入框，支持自定义问题或快速场景预填
上传音频 / 开始录音	音频文件上传与浏览器麦克风录音入口
获取安全建议	通过 WebSocket /ws/run 触发完整 pipeline
快速场景	预置密闭舱室动火、管路试压、危险拒答等 7 类演示场景
安全建议 / 安全结论 / 引用依据	主结果区，分别展示 LLM 回答、门控判定与 RAG 证据
当前问题	展示文本输入或 ASR 转写后的问题内容
运行详情	折叠区，含链路阶段、延迟指标与最近会话记录

4.2 API 接口文档

系统后端基于 FastAPI 构建，提供完整的 REST 与 WebSocket 接口。访问 /docs 可查看 Swagger 自动生成的 API 文档，证明系统为可运行的后端服务，而非静态展示页面。

default ^		
GET	/api/health	Health
GET	/api/live	Live
GET	/api/ready	Ready
GET	/api/sessions	Sessions
POST	/api/run	Run Question
GET	/api/runs/{run_id}	Run Status
POST	/api/runs/{run_id}/client-timing	Update Client Timing
GET	/api/admin/auth/status	Admin Auth Status
POST	/api/admin/auth/login	Admin Auth Login
GET	/api/admin/auth/session	Admin Auth Session
GET	/api/admin/overview	Admin Overview
GET	/api/admin/provider-health	Admin Provider Health
GET	/api/admin/jobs	Admin Jobs
GET	/api/admin/jobs/{job_id}	Admin Job Detail
GET	/api/admin/runs	Admin Runs

图 4-2 ShipVoice API 文档（Swagger UI）

主要接口分组如下：

接口路径	方法	功能
/api/health	GET	服务健康检查，返回 provider 与知识库状态
/api/run	POST	REST 方式提交问答请求
/ws/run	WebSocket	流式问答主链路，推送 event 与 audio_chunk
/api/admin/auth/login	POST	管理后台登录认证
/api/admin/overview	GET	后台总览：知识条目数、门控准确率、运行统计
/api/admin/provider-health	GET	ASR、LLM、TTS 服务可达性探测
/api/admin/knowledge	GET/POST/PUT/DELETE	知识库 CRUD
/api/admin/runs	GET	运行记录查询与导出
/api/admin/evaluations	GET	评测数据集查看
/api/admin/config	GET/POST	pipeline 配置读取与热重载

4.3 管理后台：知识治理与总览

管理后台（/admin.html）面向系统维护人员，提供知识库治理、评测触发与运行审计功能。登录后首页展示核心指标：知识条目20条、门控准确率100.0%、端到端链路延迟参考值，以及知识条目列表与在线编辑面板。



图 4-3 管理后台

图 4-3 可见内容：

- 左侧控制台动作：刷新总览、重建知识索引、重载评测数据、执行批量评测、导出日志、新建知识条目
- 知识库检索：支持按标题、标签、正文搜索，含有限空间、动火、试压等标签筛选
- 总览指标：知识条目20、最近执行0、门控准确率100.0%
- 知识条目列表：KS001密闭舱室与有限空间作业（已批准）、KS002舾装阶段管路试压、KS003船体分段吊装等
- 条目编辑：ID、标题、审核状态、负责人、来源、标签、正文、审核人、变更说明等字段均可维护

4.4 管理后台：评测概览与数据集

后台评测模块汇总 ASR、多轮问答、安全门控、真实链路等评测结果，并列对应数据集文件路径，支持答辩时一键展示实验证据。




图 4-4 管理后台评测概览

评测模块	样本规模	关键指标
安全门控	56 条	准确率待批量刷新
ASR 评测	50 条	CER 0.0%，术语召回 100.0%
多轮问答	6 组对话	Gate 100.0%，Grounding 100.0%
真实链路	3 条样本	ASR 158 ms，载荷就绪 15239 ms
当前配置	—	LLM: openai_compatible，ASR/TTS: http_json

评测数据集文件：

数据集	路径	行数
asr_eval	results/asr_eval.csv	50
multiturn_eval	results/multiturn_eval.csv	18
safety_gate_eval	results/safety_gate_eval.csv	56
real_chain_samples	results/remote_real_chain_20260612_chattts_48359/summary.json	3

后台配置面板支持直接编辑 configs/pipeline.json并热重载，当前 Admin Auth 模式为 configured_password。

4.5 管理后台：ASR评测明细与配置编辑

ASR评测明细展示50条录音清单的逐条结果，含问题文本、场景分类、CER与术语召回。后台配置编辑器可直接查看并修改pipeline参数，包括延迟目标、ASR/LLM/TTS端点等。




图 4-5 ASR 评测样本明细与 pipeline.json 配置编辑器

ASR 评测汇总指标：

指标	值
TOTAL_MANIFEST_ROWS	50
EVALUATED_ROWS	50
MISSING_AUDIO_ROWS	0
AVG_CER / AVG_WER	0
TERM_EXPECTED_COUNT	28

样本示例：A001密闭舱室动火前检查（confined_space，CER 0.0，recall 1.0）；A002 舾装阶段管路试压风险（pressure_test）；A003 船体分段吊装（lifting）；A004 压载水舱检修（ballast_tank）；A005船台阶段焊接防护（welding）；A006喷涂作业 PPE（ppe）。

配置编辑器中可见 latency_targets_ms（首段音频优秀 1800 ms、及格 3000 ms、总响应 8000ms）及ASR端点http://127.0.0.1:18001/asr。

4.6 管理后台：Provider健康检查与运行复盘

Provider Health面板对ASR、LLM、TTS三个真实服务端点发起探测。本地演示环境下远端GPU服务未启动，三个provider均显示unreachable（Connection refused），与real-only策略一致：服务不可用时前端请求失败，不在界面生成虚假结果。




图 4-6 Provider Health

Provider	端点	本地演示状态
ASR	http://127.0.0.1:18001/asr	unreachable (Connection refused)
LLM	http://127.0.0.1:18034/v1 (shipvoice-qwen2.5-7b-lora)	unreachable (Connection refused)
TTS	http://127.0.0.1:18002/tts	unreachable (Connection refused)

运行复盘面板用于定位失败请求、误拦截与延迟异常，支持设置处置状态（待处理/调查中/已解决等）、严重级别、负责人与复核备注。本地演示阶段尚无运行记录，答辩前需先启动远端GPU服务并完成至少一次真实问答，以产生可复盘的audit数据。

4.7 截图与系统能力对照

截图	对应课程要求	说明
图 4-1 用户端	可运行系统	前后端一体，支持文本/音频/录音三种输入
图 4-2 API 文档	系统架构、模块接口	15 个 REST/WebSocket 接口，非静态页面
图 4-3 知识治理	领域增强、RAG 证据	20 条船厂安全知识可 CRUD
图 4-4 评测概览	基线与改进指标	ASR/多轮/门控评测结果可后台查看
图 4-5 ASR 明细	客观指标对比	50 条录音 CER 0、术语召回 100%
图 4-6 Provider Health	模块版本与配置	端点配置可见，fail-closed 状态可观测

5. 核心模块实现

5.1 用户端工作台

用户端工作台面向船厂现场问答场景。页面默认聚焦现场问题输入框与获取安全建议按钮；用户可输入文本、上传音频或使用浏览器麦克风录音。系统返回结果后，页面优先展示安全建议、风险结论、引用依据与当前问题；链路耗时、provider 状态、运行日志等信息收纳于运行详情面板，供排障与复盘时展开查阅。

上述界面组织方式旨在使主界面贴近现场使用流程，避免技术信息过度堆叠。对现场用户而言，核心信息为问题内容、系统建议、证据依据及可执行性判断；链路指标与运行日志仍完整保留，服务于排障、实验复现与系统复盘。

5.2 ASR 与术语后处理

ASR provider通过HTTP JSON接入FunASR、SenseVoiceSmall或其他真实ASR服务。文本输入作为独立typed input处理，不伪装为语音识别结果；音频上传与浏览器录音须经真实ASR转写，服务不可用时请求失败。

为降低级联误差，项目建立造船安全术语后处理规则。典型纠错包括：西装阶段修正为舾装阶段，压在水仓修正为压载水舱，测氧测报修正为测氧测爆，冻火作业修正为动火作业等。规则定义于configs/asr_postprocess_rules.json，并通过评测脚本量化效果。

ASR清单评测含50条录音，覆盖quiet、classroom、workshop_like三类噪声条件。原始ASR平均CER/WER为1.58%，术语召回率85.71%；后处理后CER/WER为0，术语召回率提升至100%。结果表明，低成本的领域术语纠错可显著降低级联链路中听错导致答偏的风险。

5.3 安全门控

安全门控为本项目的信息安全核心模块。系统在调用RAG与LLM之前，判定输入是否属于允许回答的船厂安全问题。门控规则覆盖三类主要风险：

- off-domain：股票、医疗、娱乐、旅游、编程等与船厂安全无关的问题
- unsafe：绕过审批、伪造记录、破坏报警器、取消监护、隐瞒事故等危险请求
- prompt injection：要求系统忽略规则、扮演违规专家、输出越权方法等对抗性输入

门控设计遵循高危保守、正常放行的原则。当前安全评测集共56条样本，其中expected block 37条，expected allow 19条；标签准确率与决策准确率均为100%，false allow与false block均为0。false allow为零对本项目尤为重要：在安全场景中，危险请求误放行的代价高于个别正常问题被保守拒答。

5.4 RAG 证据检索与引用

系统回答不完全依赖语言模型自由生成，而是先从本地船厂安全知识库检索相关条目。知识库现含 20 条核心安全知识，覆盖密闭舱室、动火作业、吊装、管路试压、压载水舱、脚手架、高处作业、临时用电、消防、气体检测等典型场景。

检索结果以citation形式返回前端，字段包括知识ID、标题、来源、风险级别、置信度、标签与匹配词。引用质量评测含8个样本，gate allowed accuracy、blocked no citation rate、title hit@1/3、ID hit@3、Top-1 schema completeness与answer citation ID rate均为100%。

5.5 LLM 生成与 ShipVoice LoRA

语言模型层采用OpenAI-compatible provider，在线服务加载Qwen2.5-7B-Instruct基座与ShipVoice LoRA adapter。项目准备了SFT seed数据、扩展训练数据（1000条train / 150条 holdout）及安全门控数据，并提供remote/train_qwen_lora.py作为QLoRA微调脚本。

正式系统以RAG与安全门控约束回答边界，ShipVoice LoRA作为在线回答模型。微调主要用于增强领域表达、术语理解与多轮一致性，不替代外部安全控制。在线 LoRA adapter SHA256 为 3462dbff405f71ed3d0b0a0d8484498a2be98ffe84ab5b2f56a2d69e7130d1cf，可通过 LLM /health接口attestation验证。

5.6 TTS与低延迟体验

TTS provider 通过 HTTP 接入真实语音合成服务，响应须返回 audio_base64 与 mime_type。依据A2对首段可播放延迟的要求，pipeline记录first_audio_ms、total_ms、asr_ms、llm_first_delta_ms、server_first_audio_chunk_ready_ms、server_audio_stream_complete_ms与streamed_audio_segments等指标。

串行基线（baseline）等待 LLM 完整回答与 TTS 完整音频返回后再播放。流式改进（streaming）采用LLM token流、句级切分、TTS分段合成与WebSocket audio_chunk队列，使首句或首段音频优先播放。前端进一步记录浏览器 audio.onplaying 时间及录音路径的 client_recording_stop_to_playing_ms指标。

5.7 管理后台与运行审计

管理后台用于支撑系统持续维护与工程治理。功能包括：知识库搜索、新增、编辑、删除、版本记录与索引重建；provider 健康检查；评测数据集查看与异步评测任务；运行记录查询及异常问答沉淀为 case ledger。运行审计表记录 session_id、run_id、问题、门控结果、回答摘要、provider、延迟、错误与复盘状态。

6. 模块版本与配置说明

6.1 软件栈与运行环境

组件	版本 / 规格	说明
Python	3.10+	应用本体与实验脚本
FastAPI + Uvicorn	requirements.txt 锁定	后端 API 与 WebSocket
前端	原生 HTML/CSS/JS	无框架依赖，便于答辩演示
数据库	SQLite 3	知识库、审计、评测持久化
操作系统（本地）	Windows 10/11 或 macOS	演示机运行 FastAPI 应用
操作系统（远端）	AutoDL Ubuntu + CUDA	GPU 侧 ASR/LLM/TTS 服务
GPU（远端实验）	RTX 4090 24GB	LoRA 训练与在线推理

6.2 模型与 Provider 版本

模块	Provider 类型	模型 / 服务	部署位置
ASR	http_json	FunASR / iic/SenseVoiceSmall	远端 GPU :8001/asr
LLM	openai_compatible	Qwen/Qwen2.5-7B-Instruct + ShipVoice LoRA	远端 GPU :18034/v1
TTS	http_json	Edge-TTS zh-CN-XiaoxiaoNeural (可切换 ChatTTS/gTTS)	远端 GPU :8002/tts
RAG	hybrid	本地知识库索引 + 关键词/向量混合检索	应用内嵌
安全门控	规则引擎	关键词 + 类别标签	应用内嵌

LoRA在线服务attestation:

字段	值
served_model	shipvoice-qwen2.5-7b-lora
base_model	Qwen/Qwen2.5-7B-Instruct
adapter_loaded	true
quantization	4bit
dtype	bfloat16
device	cuda:0
adapter_sha256	3462dbff405f71ed3d0b0a0d8484498a2be98ffe84ab5b2f56a2d69e7130d1cf
adapter_bytes	177,423,363

6.3 核心配置文件

configs/pipeline.json关键字段：

配置项	当前值	含义
latency_targets_ms.first_audio_excellent	1800 ms	首段音频优秀阈值
latency_targets_ms.first_audio_pass	3000 ms	首段音频及格阈值
latency_targets_ms.total_response_pass	8000 ms	总响应及格阈值
retrieval_latency_budget_ms	160 ms	RAG 检索预算
asr.endpoint	http://127.0.0.1:18001/asr	ASR HTTP 端点
llm.model	shipvoice-qwen2.5-7b-lora	在线 LLM 模型名
llm.openai_base_url	http://127.0.0.1:18034/v1	OpenAI-compatible 基址
tts.endpoint	http://127.0.0.1:18002/tts	TTS HTTP 端点
tts.voice	zh-CN-XiaoxiaoNeural	TTS 音色
rag.top_k	3	检索返回条目数
rag.min_score	2.0	最低匹配分数
domain_terms	20 个船厂术语	ASR 后处理与检索增强
blocked_keywords	40+ 条	危险/注入拦截词
off_domain_keywords	20+ 条	越界话题拦截词

configs/runtime.real.env环境变量：

```
SHIPVOICE_ASR_PROVIDER=http_json
SHIPVOICE_ASR_ENDPOINT=http://127.0.0.1:18001/asr

SHIPVOICE_LLM_PROVIDER=openai_compatible
SHIPVOICE_OPENAI_BASE_URL=http://127.0.0.1:18034/v1
SHIPVOICE_LLM_MODEL=shipvoice-qwen2.5-7b-lora
SHIPVOICE_REQUIRE_LORA=1
SHIPVOICE_REQUIRE_LLM_MODEL_SUBSTRING=shipvoice

SHIPVOICE_TTS_PROVIDER=http_json
SHIPVOICE_TTS_ENDPOINT=http://127.0.0.1:18002/tts
SHIPVOICE_TTS_VOICE=zh-CN-XiaoxiaoNeural

SHIPVOICE_ADMIN_PASSWORD=shipvoice-admin
SHIPVOICE_APP_PORT=8026
```

6.4 Provider接口约定

ASR请求与响应：

```
// POST /asr
{ "audio_base64": "...", "audio_name": "sample.wav" }
// Response
{ "text": "转写文本" }
```

LLM 请求：OpenAI-compatible POST /v1/chat/completions；streaming 模式设置 stream=true并解析SSE delta。

TTS请求与响应：

```
// POST /tts
{ "text": "要合成的回答", "voice": "zh-CN-XiaoxiaoNeural" }
// Response
{ "audio_base64": "...", "mime_type": "audio/wav" }
```

6.5 延迟测量点定义

指标字段	测量起点 → 终点	用途
asr_ms	请求开始 → ASR 返回	ASR 阶段耗时
llm_first_delta_ms	请求开始 → LLM 首个 token (仅 streaming)	流式首 token 延迟
llm_complete_ms	请求开始 → LLM 完整回答	LLM 生成总耗时
first_audio_ready_ms / server_first_audio_chunk_ready_ms	请求开始 → 首个音频片段 ready	服务端首播 (A2 核心指标)
server_audio_stream_complete_ms	请求开始 → 全部 audio_chunk 完成	完整语音输出耗时
client_audio_onplaying_ms	浏览器提交 → audio.onplaying 触发	用户侧真实听到声音的时间
client_recording_stop_to_playing_ms	停止录音 → 首段音频播放	用户说完至听到回复的端到端延迟

7. 数据集与知识资产建设

项目构建的数据资产如下：

资产类型	规模	文件路径	用途
船厂安全知识库	20 条	data/knowledge/ship_safety_corpus.jsonl	RAG 检索与 citation
安全门控评测集	56 条	data/tests/safety_eval.csv	off/unsafe/injection/boundary 评测

资产类型	规模	文件路径	用途
真实录音清单	50 条	data/audio/audio_manifest.csv	ASR 术语与噪声条件评测
A2 难度分层清单	50 条（四层）	data/audio/audio_manifest_a2_eval.csv	L1–L4 固定音频指令集
SFT 扩展训练集	1000 / 150	data/training/shipvoice_sft_train_expanded.jsonl	LoRA 微调与 holdout 评测
安全门控 seed	32 条	data/training/	门控规则与对抗样本参考

A2 固定音频指令集四层划分：L1基础安全问答1条，L2船厂专有名词9条，L3噪声/应急复杂处置11条，L4安全边界与对抗输入29条。详见 docs/FIXED_AUDIO_COMMAND_SET_20260623.md。

8. 基线与改进方案

8.1 基线定义

本项目将基线（baseline）定义为串行级联链路：

输入 → ASR → [无术语纠错] → [无安全门控] → [无 RAG] → LLM 完整生成 → TTS 完整合成 → 一次返回播放

实现上，baseline模式对应pipeline的response_mode=baseline：等待LLM输出完整文本后，再调用 TTS 合成完整音频并一次性返回。该基线可完成基本问答，但存在以下局限：（1）ASR误听直接传递至LLM，导致检索与回答偏移；（2）LLM可能对越界或危险请求继续生成；（3）回答缺乏来源依据，难以审计；（4）首段可播放延迟较高，用户等待体验不佳。

8.2 改进版ShipVoice

改进版在基线基础上集成以下模块：

序号	改进模块	解决的问题	实现位置
1	ASR 术语后处理	专有名词误听导致级联误差	configs/asr_postprocess_rules.json
2	安全门控	危险/越界/注入输入未拦截	src/shipvoice/providers.py + pipeline
3	RAG 证据检索	回答无依据、幻觉风险	data/knowledge/ + hybrid retriever
4	Citation 展示	用户无法验证答案来源	前端 + API 响应 schema
5	多轮上下文	追问无法绑定前文	history 字段 + multiturn eval
6	Streaming 低延迟	首段音频等待过长	LLM SSE + 句级 TTS + WebSocket chunk
7	双端延迟指标	服务端与用户端体验不一致	pipeline metrics + 浏览器 onplaying

序号	改进模块	解决的问题	实现位置
8	管理后台与审计	无法持续维护与复盘	admin.html + SQLite
9	Real-only provider	演示结果不可信	fail-closed + health check
10	固定音频集评测	缺乏可重复对比证据	30×2×5 重复实验 + 浏览器批量取证

8.3 改进前后能力对比（定性）

能力维度	基线	改进版 ShipVoice
危险请求处理	可能继续生成	门控短路，false allow = 0
答案可解释性	无 citation	ID/来源/风险级别/匹配词
ASR 术语鲁棒性	原始转写	后处理术语召回 100%
首段可播放延迟	~7967 ms (gate-allowed 均值)	~3820 ms (streaming 均值)
多轮追问	不支持或弱	follow-up grounding 100%
运行可审计	无	SQLite 审计 + case ledger
服务真实性	可能 mock	real-only，缺失即失败

9. 实验设计与结果

9.1 实验总览

实验编号	实验名称	样本规模	主要指标	结果文件
E1	安全门控评测	56	决策准确率、false allow	results/safety_gate_eval_summary.json
E2	ASR 术语后处理	50	CER/WER、术语召回	results/asr_eval_summary.json
E3	多轮问答	6 组 18 轮	grounding、keyword recall	results/multiturn_eval_summary.json
E4	Citation 质量	8	hit@3、schema 完整率	results/citation_quality_summary.json
E5	真实链路重复实验	300 (30×2×5)	首段延迟、配对节省	results/server_real_repeated_20260623/
E6	浏览器首播观测	20	audio.onplaying	results/ browser_onplaying_streamable_20260623.json
E7	等待体验代理评分	100 配对	1—5 级体验分	results/waiting_experience_20260623/

9.2 安全门控评测（E1）

指标	结果
总样本数	56
expected block	37
expected allow	19
标签准确率	100%
决策准确率	100%
false allow	0
false block	0
block recall	100%
allow recall	100%

按类别统计：off_domain 11条、unsafe 15条、prompt_injection 10条、domain_safe 15条、boundary 5条，均与预期一致。

9.3 ASR术语后处理评测（E2）

指标	Raw ASR	后处理后
评测样本	50	50
缺失音频	0	0
平均 CER/WER	1.58%	0.00%
术语命中数	24 / 28	28 / 28
术语召回率	85.71%	100%
变更行数	—	12

典型纠错：西装阶段→舾装阶段，压在水仓→压载水舱，测氧测报→测氧测爆，冻火作业→动火作业。

9.4 多轮问答评测（E3）

指标	结果
对话数	6
总轮次	18
follow-up 轮次	12
gate accuracy	100%
top1 title accuracy	100%
title hit@3	100%

指标	结果
keyword recall	97.22%
follow-up grounding accuracy	100%
平均首音频耗时	1516 ms
平均总耗时	2920 ms

9.5 Citation引用质量评测（E4）

指标	结果
总样本	8
允许回答样本	5
拦截样本	3
gate allowed accuracy	100%
blocked no citation rate	100%
title hit@1 / hit@3	100%
ID hit@3	100%
Top-1 schema completeness	100%
answer citation ID rate	100%

9.6 基线 vs 改进：延迟与客观指标对比（E5）

实验设置：30条固定录音（A001—A030），baseline与streaming各重复5次，共300次 real-only运行；ASR为SenseVoiceSmall，LLM为ShipVoice LoRA，TTS为Edge-TTS；num_ok=300，num_failed=0。

表 9-1 总体运行统计

指标	串行基线 baseline	流式改进 streaming
总运行次数	150	150
失败次数	0	0
gate-allowed 样本数	100	100
流式音频片段均值	0	3.87

表 9-2 gate-allowed样本阶段延迟对比（A2 核心指标）

指标	串行基线 baseline	流式改进 streaming	改进幅度
ASR 均值	326.31 ms	317.63 ms	−8.68 ms
LLM 首 token 均值	0 ms（非流式）	219.29 ms	流式启用

指标	串行基线 baseline	流式改进 streaming	改进幅度
LLM 完整生成均值	4960.18 ms	5254.60 ms	相当
首段可播放延迟均值	7967.04 ms	3819.65 ms	−4147.39 ms (52.1%)
首段可播放延迟 P50	7373.5 ms	3869.0 ms	−3504.5 ms
首段可播放延迟 P90	11987.5 ms	5110.7 ms	−6876.8 ms
完整音频流完成均值	7967.04 ms	8178.61 ms	总完成时间相当
流式音频片段数均值	0	3.87	—

表 9-3 100个gate-allowed配对样本差值统计

指标	数值
配对样本数	100
streaming 首段更快次数	100 / 100
streaming 首段更慢次数	0 / 100
平均节省时间	4147.39 ms
P50 节省时间	3416.0 ms
P90 节省时间	7659.0 ms
最小节省	496.0 ms
最大节省	11210.0 ms

streaming模式的核心价值在于提前首段可播放时间，而非缩短LLM完整生成时间。用户可在完整回答尚未生成完毕时先听到首句安全建议，从而改善主观等待体验。

表 9-4 全部150配对样本（含gate-blocked）差值

指标	数值
配对样本数	150
streaming 首段更快次数	126 / 150
平均节省时间	2761.38 ms

gate-blocked样本因拒答路径较短，部分样本baseline与streaming差异有限；全量配对不如gate-allowed子集能充分体现streaming优势。A2对比应以gate-allowed 100配对为主证据。

表 9-5 浏览器端首播观测（E6）

指标	结果
样本数	20
成功 / 失败	20 / 0

指标	结果
client_audio_onplaying_ms 均值	4093.5 ms
P50	4072.0 ms
P90	5600.1 ms
最小 / 最大	2242 / 5867 ms
server_first_audio_chunk_ready_ms 均值	3810.05 ms
llm_first_delta_ms 均值	214.9 ms

浏览器端指标涵盖网络传输、前端队列与音频元素启动时间，更贴近用户侧真实感受。

表 9-6 主观等待体验代理量化（E7）

指标	串行基线	流式改进	浏览器 streaming
配对样本数	100	100	20
首段可播放延迟均值	7967.04 ms	3819.65 ms	4093.5 ms
等待体验等级均值（1-5）	2.02	3.71	3.60

等级规则：≤2500ms记5级；≤4000ms记4级；≤6000ms记3级；≤9000ms记2级；>9000ms记1级。该方法基于真实延迟日志生成代理指标，非真人Likert问卷结果。

表 9-7 综合客观指标汇总

指标组	关键结果
安全门控	56 样本，决策准确率 100%，false allow 0
ASR 术语	50 录音，后处理术语召回 100%，CER/WER 0%
多轮问答	18 轮，follow-up grounding 100%
Citation	hit@3 100%，答案引用 ID 100%
真实链路	300 次全成功，streaming 100/100 配对更快
浏览器首播	20/20 成功，均值 4093.5 ms
LoRA attestation	adapter SHA256 已验证在线加载

10. 信息安全设计

本项目所属课程为信息安全基础，因此须在展示模型能力的同时体现安全防护设计。ShipVoice 的安全架构涵盖四个层面。

输入安全：安全门控处理越界问题、危险请求与提示注入。典型对抗样本（如要求忽略安全规则、伪装违规专家身份、询问绕过动火审批的方法等）不进入常规生成流程。

生成安全：RAG与固定安全策略约束回答内容。对允许回答的问题，系统优先给出风险判断、必要检查、禁止事项与升级处置建议；对高风险场景，强调停止作业、通风、检测、监护、审批及现场负责人确认，而非输出不受约束的操作步骤。

证据安全：前端展示知识条目 ID、来源、风险级别与匹配词，确保回答具备可追溯出处；后台支持知识库维护，变更后可重建索引。

运维安全：后台采用管理员口令认证，运行记录持久化至 SQLite，异常记录可进入case ledger。当前为单管理员模式，已具备审计、复盘与治理的基本能力。

11. 可复现实验步骤

ShipVoice 提供**两条复现链路**：**链路一**在普通 CPU 笔记本上即可完成，用于验证系统可运行性、安全门控与大部分客观指标；**链路二**在远端GPU上启动ASR、ShipVoice LoRA LLM与TTS，用于完整ASR → LLM → TTS级联问答、延迟对比及第9章300次真实链路重复实验。本机不必安装GPU；链路二的GPU通常部署在AutoDL等远端机器，经SSH隧道映射到本地。

本地安装依赖后，在项目根目录启动系统：

```
cd ShipVoice
python -m pip install -r requirements.txt
$env:SHIPVOICE_ADMIN_PASSWORD="shipvoice-admin"
python run_app.py --port 8026
```

打开用户端：

```
http://127.0.0.1:8026/
```

打开管理后台：

```
http://127.0.0.1:8026/admin.html
```

默认后台密码为：

```
shipvoice-admin
```

运行单元测试：

```
python -m pytest tests -q
```

刷新项目验收报告：

```
python scripts\build_acceptance_report.py
```

运行安全门控评测：

```
python scripts\evaluate_safety_gate.py --gate-only
```

运行多轮问答评测：

```
python scripts\evaluate_multiturn.py
```

运行 ASR 清单评测：

```
python scripts\evaluate_asr_transcripts.py
```

生成固定音频指令集难度梯度：

```
python scripts\build_a2_audio_eval_manifest.py
```

运行 citation 质量评测：

```
python scripts\evaluate_citation_quality.py --fail-on-threshold
```

生成等待体验代理评分：

```
python scripts\evaluate_waiting_experience.py
```

若要接入真实 ASR、LLM、TTS 并完成完整语音问答链路，须先在远程 GPU 机器（如 AutoDL）启动相关服务，再设置 configs/runtime.real.env 中的 endpoint，并使用该配置启动应用：

```
python run_app.py --env-file configs\runtime.real.env --port 8026
```

真实链路验证与第 9 章主证据应以以下文件为准：

```
results/server_real_repeated_20260623/summary.json  
results/server_real_batch_comparison_20260623.json  
results/browser_onplaying_streamable_20260623.json  
results/waiting_experience_20260623/summary.json  
results/lora_adapter_attestation_20260623.json
```

12. 改进点总结

结合课程 A2 对时序与体验、质量、安全模块衔接三个方向的要求，ShipVoice 的改进点归纳如下。

12.1 时序与体验改进

(1) Streaming句级TTS: LLM token流、句级切分与分段TTS使首段可播放延迟由7967ms降至3820ms (gate-allowed 均值), 100个配对样本streaming均更快。

(2) WebSocket audio_chunk: 服务端合成一段即推送一段, 前端队列播放, 避免等待完整音频。

(3) 双端延迟测量: 同时记录服务端first_audio_ready_ms与浏览器audio.onplaying, 以及录音路径client_recording_stop_to_playing_ms。

(4) 等待体验代理量化: 将延迟映射为1-5级体验分, baseline2.02, streaming3.71。

12.2 质量改进

(1) ASR术语后处理: 术语召回由85.71%提升至100%, 降低级联误差。

(2) RAG证据引用: 回答绑定知识ID、来源与风险级别, citation hit@3 100%。

(3) 多轮上下文: 6组18轮对话, follow-up grounding 100%。

(4) ShipVoice LoRA: 1000条扩展SFT微调, 增强领域表达与术语理解。

(5) 固定音频集分层: 50条录音按L1-L4难度分层, 覆盖基础问答至对抗输入。

12.3 安全模块衔接改进

(1) 门控前置: 危险、越界与注入类输入在LLM之前拦截, false allow = 0。

(2) Fail-closed: 真实服务缺失时直接失败, 不返回mock结果。

(3) Blocked无citation: 被拦截样本不伪造引用, blocked no citation rate 100%。

(4) 运行审计: 每次问答落库run_id、门控结果、延迟与错误, 支持case ledger复盘。

(5) 管理后台治理: 知识库CRUD、provider health与评测任务, 体现工程可维护性。

13. 当前局限与后续工作

13.1 实验规模

真实端到端语音链路已完成300次固定音频集重复实验, 但仍属课程规模评测, 不等同于船厂长期生产压测。说话人、噪声条件与场景覆盖仍有限。

13.2 延迟体验

浏览器首播平均约4.1秒, 已显著优于串行基线 (约8秒), 但距企业级语音助手2秒内自然接话的目标仍有差距。当前TTS按句返回完整片段, 非字节级流式合成; 后续可引入CosyVoice流式TTS、缓存预热与更细粒度分片。

13.3 主观体验

等待体验采用自动化代理量化等级, 非真人Likert问卷。后续可补充小规模现场听感调研。

13.4 知识库规模

当前知识库含20条核心条目，适用于验证RAG引用与安全问答闭环，但与真实船厂完整规程库存在数量级差距。后续须接入真实制度文件并增加来源可信度评估。

13.5 工程部署

当前数据库为SQLite，后台认证为单管理员口令，适用于课程演示与单机原型。企业级部署须迁移至PostgreSQL，并补充RBAC、对象存储、异步队列、监控告警与灰度发布机制。

13.6 服务依赖

real-only策略要求ASR、LLM、TTS持续在线。答辩现场若GPU或网络不稳定，应展示已归档的真实链路JSON证据，而非离线mock。

13.7 后续优化方向

- (1) 扩展真实端到端评测至更多说话人、噪声条件与更长多轮任务；
- (2) 引入流式TTS或更快中文语音合成，目标浏览器首播低于2500ms；
- (3) 扩大知识库并建立来源可信度与版本管理；
- (4) 开展LoRA系统级A/B对比与安全偏好DPO；
- (5) 补充RBAC、审批流与企业部署文档；
- (6) 在管理后台建立评测结果趋势看板与版本回归对比。

14. 总结

ShipVoice完成了课程A2要求的级联式造船语音问答系统，并在此基础上实现了安全门控、RAG证据引用、术语后处理、多轮评测、真实provider接入、流式低延迟优化、管理后台与运行审计。项目具备可运行系统、固定音频集、基线与流式改进对比、浏览器首播观测、等待体验量化指标及可复现文档等完整交付物。

本项目的核心价值在于：系统将语音问答能力置于船厂安全场景的风险控制、证据可信、审计复盘与工程可维护性框架之内，而非停留在基本问答功能的层面。据此，ShipVoice更接近可演进的安全助手原型，而非一次性展示页面。